

גישות חישוביות – תרגיל 4

1.


a.

λ הוא המקדם לסכום על ξ כדי להעניש דוגמאות שסווגו לא נכון. באופן כללי, מייצר איזון בין שתי אפשרויות:


λ גדול לא מאפשר דוגמאות סוררות, ה $margin$ יהיה קטן.
 λ קטן לא נענש על דוגמאות סוררות, ה $margin$ יכול להיות גדול יותר.

מהרצת ה $data$ של אופציה 5 (סט של שתי ספירלות), שאינו ניתן להפרדה ליניארית, ראינו של λ קטן מאפשר טעויות על הדוגמאות ול λ גדול מייצר הפרדה קשיחה.

λ קטן:



λ גדול:



b.

קלט:

H – מטריצת קרנל סימטרית בגודל $n * n$ כאשר n גודל ה $data set$, מקיימת:

$$H(i, j) = H(j, i) = y_i * y_j * K(x_i, x_j) = y_i * y_j * e^{-\beta \|x_i - x_j\|^2}$$

f – תנאי ליניארי, בתרגיל שלנו וקטור מינוס אחדות בגודל n .

lb – חסם תחתון על וקטור המשתנים z שמחפשים כדי לפתור את המשוואה, כלומר $lb \leq z$, בתרגיל $0 \leq z$.

ub – חסם עליון על וקטור המשתנים z שמחפשים כדי לפתור את המשוואה, כלומר $z \leq ub$, בתרגיל $z \leq \infty$.

Aeq – וקטור התיוגים של הדוגמאות, בגודל $1 * n$.

Beq – ערך המכפלה הנדרש עבור $Aeq * z = Beq$ (כלומר צריך להתקיים $Aeq * z = Beq$ עבור ה z הנבחר).

פלט:

מחזירה את וקטור המקדמים z בגודל $1 * n$.

אופן הפעולה:

הפונקציה מאתרת את וקטור המקדמים z שפותר את המשוואה: $\frac{1}{2} * z^T H z + f^T z$, תחת

האילוץ $lb \leq z \leq ub, Aeq * z = Beq$.

c.

ה $bias$ מחושב לפי הנקודות שנבחרו כ $near\ boundary$. עבור וקטור nb של לכל היותר n נקודות (כאשר סט האימון מכיל n דוגמאות) הפונקציה מחשבת:

1. לכל i ב nb :

$$\frac{1}{y(i)} - f(x) \rightarrow temp(i)$$

2. $bias = mean(temp)$.

כלומר עבור תיוגים $\{-1,1\}$ בבעיית הכרעה בינארית הפונקציה מחשבת את ה $bias$ להיות הממוצע של ההפרשים בין התיוג האמיתי לחיזוי עבור הדוגמאות של nb .

d.

: $SVMtrial(x, y, kw, \lambda)$

1. נרמל את x .

2. $x \rightarrow x^T$.

3. $\begin{pmatrix} -1 \\ \vdots \\ -1 \end{pmatrix} \rightarrow f$, $Aeq \rightarrow y^T$, $Beq \rightarrow 0$, $lb \rightarrow (0, \dots, 0)$, $ub \rightarrow \lambda$

4. הפק מטריצת קרנל H

a. לכל $j, 1 \leq j \leq n$:

i. לכל $i, 1 \leq i \leq j$:

1. $x(j) - x^T(i) \rightarrow d$

2. $y_j y_i K(x_i, x_j) \rightarrow H(j, i)$

// בתרגיל $K(x_i, x_j) =$

$$e^{-\frac{\|d\|^2}{kw}}$$

3. $H(j, i) \rightarrow H(i, j)$

5. הרץ $a \rightarrow quadratic\ program(H, f, Aeq, Beq, lb, ub)$

6. עדכן $support\ vectors\ (sv)$ ע"מ לאפשר טעות קטנה $(0 < a < \varepsilon\ or\ \lambda < a < \lambda - \varepsilon)$

7. חשב את ה $bias(b)$ (כפי שתואר בסעיף 1.c).

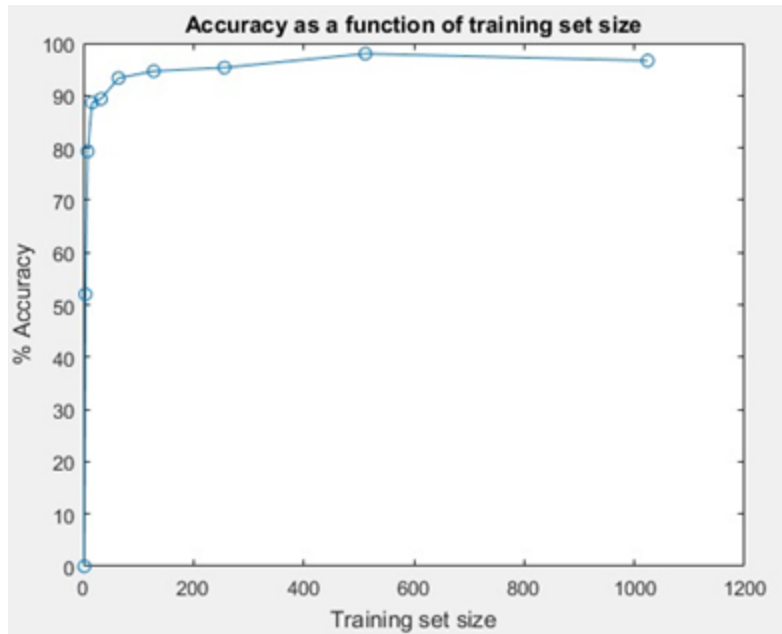
8. החזר F כאשר המכיל את x, y, sv, kw, a, b .

2.

a. מומש.

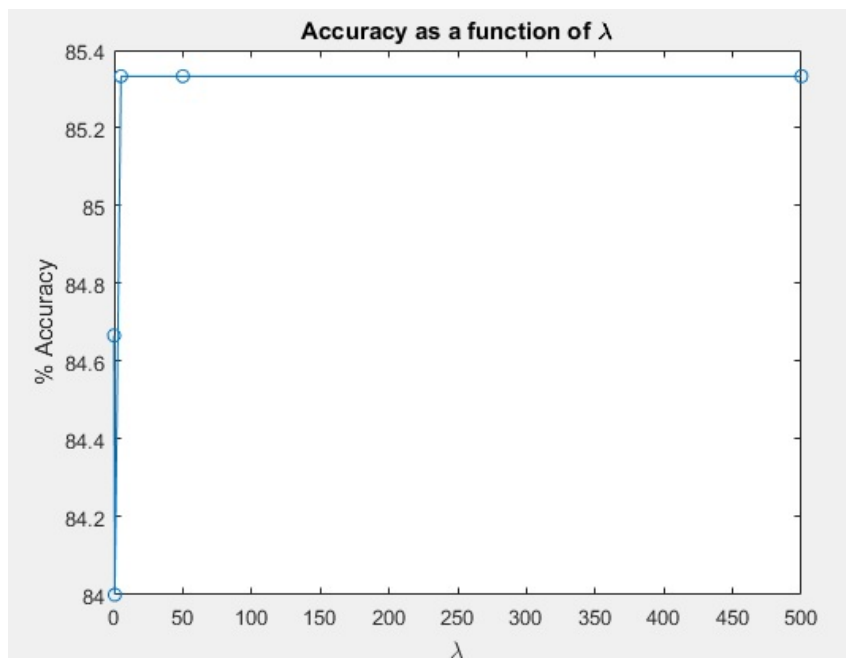
b. עבור 3 החלוקות של ה $data\ set$ קיבלנו אחוזי דיוק של 86,84,92 , אחוז הדיוק הממוצע $87\frac{1}{3}$.

c. ניתן לראות שכלל שמגדילים את כמות הדוגמאות ב $training\ set$ אחוזי הדיוק על סט הולידציה עולים. בנוסף, עבור $training\ set$ בגודל 2 ה $bias$ חושב כNaN מכיוון שלא נמצאו $support\ vectors$, דבר שפגע ביצירת התיוג, ולכן אחוז הדיוק הוא 0.



d. קיבענו $training\ set$ בגודל 10 דוגמאות וסט ולידציה של 50 דוגמאות, להלן אחוזי הדיוק כפונקציה של λ :

λ	0.005	0.5	5	50	500
Accuracy(%)	84.667	84	85.33	85.33	85.33



ניתן לראות בתוצאות שמתקבלים אחוזי דיוק דומים עבור ערכי λ השונים. ייתכן שנובע מסט אימון קטן מדי ולכן הענישה עבור דוגמאות סוררות לא באה לידי ביטוי.

נניח $data\ set$ של n דוגמאות מתויגות $(x_1, y_1), \dots, (x_n, y_n)$. תהי מטריצה H בגודל $n * n$,

$$H = \begin{bmatrix} y_1 y_1 K(x_1, x_1) & \cdots & y_1 y_n K(x_1, x_n) \\ \vdots & \ddots & \vdots \\ y_n y_1 K(x_n, x_1) & \cdots & y_n y_n K(x_n, x_n) \end{bmatrix}$$

ה $kernel$ על הדוגמאות. נייצר וקטור משתנים $Z = \begin{pmatrix} z_1 \\ \vdots \\ z_n \end{pmatrix}$ ותנאי ליניארי $f = \begin{pmatrix} -1 \\ \vdots \\ -1 \end{pmatrix}$ (נבחר בתרגיל).

כעת נראה שקילות בין פיתרון ה $quadprog$ לפיתרון SVM בעזרת $slack\ variables$.
נעשה זאת על ידי הוכחת שקילות בין $quadprog$ לבעיה הדואלית יחד עם שקילות בין הבעיה הדואלית לבעיה הפרימלית.

א. שקילות בין פיתרון $quadprog$ לבעיה הדואלית:

$$\min_z \frac{1}{2} * z^T H z + f^T z \quad , \quad \text{such that } lb \leq z \leq ub, \quad Aeq * z = Beq, \quad \text{where } Aeq = y^T$$

\Leftrightarrow

$$\min_z \frac{1}{2} * (z_1, \dots, z_n) \begin{bmatrix} y_1 y_1 K(x_1, x_1) & \cdots & y_1 y_n K(x_1, x_n) \\ \vdots & \ddots & \vdots \\ y_n y_1 K(x_n, x_1) & \cdots & y_n y_n K(x_n, x_n) \end{bmatrix} \begin{pmatrix} z_1 \\ \vdots \\ z_n \end{pmatrix} + (-1, \dots, -1) \begin{pmatrix} z_1 \\ \vdots \\ z_n \end{pmatrix}$$

\Leftrightarrow

$$\min_z \frac{1}{2} * (z_1, \dots, z_n) \begin{bmatrix} y_1 y_1 K(x_1, x_1) & \cdots & y_1 y_n K(x_1, x_n) \\ \vdots & \ddots & \vdots \\ y_n y_1 K(x_n, x_1) & \cdots & y_n y_n K(x_n, x_n) \end{bmatrix} \begin{pmatrix} z_1 \\ \vdots \\ z_n \end{pmatrix} - \sum_{j=1}^n z_j$$

\Leftrightarrow

$$\min_z \frac{1}{2} * (z_1, \dots, z_n) \begin{pmatrix} \sum_{i=1}^n y_1 y_i K(x_1, x_i) z_i \\ \vdots \\ \sum_{i=1}^n y_n y_i K(x_n, x_i) z_i \end{pmatrix} - \sum_{j=1}^n z_j$$

\Leftrightarrow

$$\min_z \frac{1}{2} * \left(\sum_{i=1}^n y_1 y_i K(x_1, x_i) z_1 z_i + \cdots + \sum_{i=1}^n y_1 y_i K(x_1, x_i) z_n z_i \right) - \sum_{j=1}^n z_j$$

\Leftrightarrow

$$\min_z \frac{1}{2} * \left(\sum_{j=1}^n \sum_{i=1}^n y_j y_i K(x_j, x_i) z_j z_i \right) - \sum_{j=1}^n z_j$$

\Leftrightarrow

$$\max_z - \left(\frac{1}{2} * \left(\sum_{j=1}^n \sum_{i=1}^n y_j y_i K(x_j, x_i) z_j z_i \right) - \sum_{j=1}^n z_j \right)$$

\Leftrightarrow

$$\max_z \sum_{j=1}^n z_j - \frac{1}{2} \left(\sum_{j=1}^n \sum_{i=1}^n y_j y_i K(x_j, x_i) z_j z_i \right) \quad , \quad \text{such that : } \sum_{j=1}^n z_j y_j = 0$$

מקסימום על X שקול
למינימום על $-X$

ב. כעת נותר להראות שקילות בין הבעיה הדואלית לבעיה הפרימלית, כלומר :

$$\max_z \sum_{j=1}^n z_j - \frac{1}{2} \left(\sum_{j=1}^n \sum_{i=1}^n y_j y_i K(x_j, x_i) z_j z_i \right) \Leftrightarrow \min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

כאשר עבור הבעיה הפרימלית: $(w^T x_i + b)y_i \geq 1 - \xi_i$, $\sum_{i=1}^n \xi_i \geq 0$,
רוצים להביא למינימום את w , $w = \sum_{j=1}^n z_j x_j y_j$.

עבור הבעיה הדואלית דורשים: $\sum_{j=1}^n z_j y_j = 0$

הוכחה:

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i , \quad \text{such that: } (w^T x_i + b)y_i \geq 1 - \xi_i , \sum_{i=1}^n \xi_i \geq 0 , \quad \text{where } w = \sum_{j=1}^n z_j x_j y_j$$

\Leftrightarrow

$$\max_z \min_{w,b} \frac{1}{2} \|w\|^2 - \sum_{i=1}^n z_i ((w^T x_i + b)y_i - 1)$$

\Leftrightarrow

$$\max \frac{1}{2} \sum_{i=1}^n z_i x_i y_i \sum_{j=1}^n z_j x_j y_j - \sum_{i=1}^n z_i \left(\left(\sum_{j=1}^n z_j x_j y_j x_i + b \right) y_i - 1 \right)$$

\Leftrightarrow

$$\max \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n z_i x_i y_i z_j x_j y_j + \sum_{i=1}^n z_i - \sum_{i=1}^n z_i \left(\left(\sum_{j=1}^n z_j x_j y_j x_i + b \right) y_i \right)$$

\Leftrightarrow

$$\max \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n z_i x_i y_i z_j x_j y_j + \sum_{i=1}^n z_i - \sum_{i=1}^n b z_i y_i - \sum_{i=1}^n z_i y_i x_i \sum_{j=1}^n z_j x_j y_j$$

\Leftrightarrow

$$\max \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n z_i x_i y_i z_j x_j y_j + \sum_{i=1}^n z_i - \sum_{i=1}^n \sum_{j=1}^n z_i x_i y_i z_j x_j y_j$$

\Leftrightarrow

$$\max \sum_{i=1}^n z_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n z_i x_i y_i z_j x_j y_j \quad \text{such that: } \sum_{j=1}^n z_j y_j = 0 \quad \blacksquare$$

4.

בחרנו להחליף את פונקציית הkernel שהייתה בקוד, ב RBF , בפונקציית הקרנל הגאוסיאנית:


$$K(x_1, x_2) = -\frac{||x_1 - x_2||^2}{2\sigma^2}$$

מימשנו את החלפת הפונקציה והרצנו על גבי הסטים 1-6 הנתונים. לטובת ההיפרפרמטר σ בחרנו ערכים שונים
בניתוחים השונים.

ביצענו שני ניתוחים:

- א. השוואת אחוזי הדיוק עבור $Data Sets$ שונים בין שני הקרנלים (RBF עם $kw = \frac{1}{4}$ ו- $Gaussian$ עם $\sigma = 1$).
ראינו שאחוזי הדיוק נשארים יחסית דומים ללא מגמה.
- ב. השוואת אחוזי הדיוק עבור $Data Set$ רנדומלי עם תיוגים שנקבעים לפי חוקיות (4) עבור σ משתנה. ראינו
שערכי σ של 0.5, 1 נותנים את הביצועים הטובים ביותר, כשהגדלה והקטנה פוגעות בהדרגה באחוזי הדיוק.

להלן התוצאות:



Data Set	Name
1	Linearly Seperable
2	Non-Linearly Seperable
3	Random Set
4	Random Set - Labels Determined By Rule
5	Two Spirals
6	Imbalance

